

PROJET P02 · DATA SCIENCE · MÉTHODOLOGIE CRISP-DM

Scoring de Crédit pour une Institution de Microfinance

Accorder ou refuser un microcrédit à un commerçant du marché de Madina

Rapport de projet

Données : 1 500 clients · 19 variables · adapté du dataset Give Me Some Credit

Auteur : AMNI AYOUBA MHOMA

Date : Août 2026

Table des matières

1. Introduction et contexte métier	3
2. Compréhension des données	3
3. Préparation des données.....	6
4. Modélisation	7
5. Évaluation des modèles.....	8
6. Interprétation — variables les plus explicatives	10
7. Déploiement.....	11
8. Limites et pistes d'amélioration.....	11
9. Conclusion	12

1. Introduction et contexte métier

Ce rapport présente la démarche complète d'un projet de scoring de crédit destiné à une institution de microfinance (IMF) opérant sur le marché de Madina. L'objectif est de construire un modèle statistique capable d'estimer la probabilité qu'un commerçant, sollicitant un microcrédit, fasse défaut sur son remboursement, afin d'éclairer la décision d'octroi ou de refus prise par l'agent de crédit.

Le projet suit intégralement la méthodologie CRISP-DM (Cross-Industry Standard Process for Data Mining), qui structure le travail en six phases : compréhension métier, compréhension des données, préparation, modélisation, évaluation et déploiement. Chacune de ces phases est détaillée dans les sections suivantes.

1.1 La décision à éclairer

La décision opérationnelle visée est binaire : accorder ou refuser un microcrédit à un commerçant du marché de Madina. Cette décision est prise par l'agent de crédit ou le comité d'octroi de l'IMF, qui dispose d'un dossier de candidature contenant le profil du commerçant, son activité, son historique de crédit et les caractéristiques du prêt demandé.

1.2 Enjeux et utilisateurs

L'enjeu métier est double : d'une part, réduire le risque de défaut de paiement qui pèse directement sur la pérennité financière de l'IMF ; d'autre part, préserver l'inclusion financière des commerçants informels du marché, qui constituent le cœur de cible de la microfinance et n'ont généralement pas accès au crédit bancaire classique. Un modèle trop strict exclurait des clients solvables ; un modèle trop permissif exposerait l'IMF à des pertes importantes.

- Faux négatif (client à risque accepté) : perte financière directe pour l'IMF, le prêt n'étant pas remboursé.
- Faux positif (bon client refusé) : exclusion financière d'un commerçant solvable et perte d'opportunité commerciale pour l'IMF.

1.3 Contrainte réglementaire

Le régulateur impose que les décisions de crédit puissent être justifiées de manière transparente auprès du client et de l'autorité de supervision. Cette exigence d'interprétabilité place la régression logistique au centre de la démarche : elle sert de modèle de référence, ses coefficients pouvant être directement traduits en facteurs de risque ou de protection compréhensibles par un agent de crédit non data-scientist.

2. Compréhension des données

Cette phase vise à décrire précisément le jeu de données mobilisé, à en vérifier la qualité et à explorer les distributions et relations entre variables avant toute modélisation.

2.1 Vue d'ensemble du jeu de données

Le jeu de données P02_scoring_credit_madina.csv comprend 1 500 clients (lignes) et 19 variables explicatives, auxquelles s'ajoute la variable cible `default_paiement`. Il s'agit d'un jeu de données simulé, adapté au contexte local à partir de la structure du dataset Give Me Some Credit (Kaggle) et du jeu de données UCI German Credit mentionnés dans l'énoncé du projet.

- 1 500 observations, 19 variables explicatives + 1 variable cible
- Aucune valeur manquante détectée sur l'ensemble des colonnes (0 %)
- 8 secteurs d'activité représentés : Alimentation, Vêtements, Tissus_Pagnes, Cosmétiques, Chaussures, Électronique_Téléphonie, Quincaillerie, Divers

2.2 Dictionnaire des variables

Catégorie	Variables	Description
Profil du commerçant	age, genre, situation_matrimoniale, nb_personnes_charge	Caractéristiques démographiques du demandeur
Activité commerciale	secteur_activite, anciennete_activite_annees, revenu_mensuel_gnf	Nature et ancienneté de l'activité, revenu déclaré
Inclusion financière	membre_tontine, possede_mobile_money, membre_association_marchands	Indicateurs d'ancrage dans l'écosystème financier local
Historique de crédit	nb_credits_antérieurs, a_deja_eu_retard, jours_retard_max_antérieur, score_bureau_credit, garant_disponible	Comportement de remboursement passé et solidité du dossier
Caractéristiques du prêt	montant_pret_demande_gnf, duree_pret_mois, ratio_pret_revenu	Paramètres du crédit sollicité
Variable cible	default_paiement	0 = remboursement, 1 = défaut de paiement

Tableau 1 — Dictionnaire synthétique des variables du jeu de données

2.3 Statistiques descriptives

Le tableau suivant résume les statistiques descriptives des principales variables numériques (moyenne, écart-type, minimum, médiane, maximum). Le revenu mensuel moyen s'élève à environ 3,67 millions GNF, avec une forte dispersion. L'âge médian des commerçants est de 38 ans, et la durée médiane du prêt demandé de 9 mois.

Variable	Moyenne	Médiane	Écart-type	Min	Max
age (ans)	37,5	38	10,6	18	72
revenu_mensuel_gnf	3 670 053	3 162 000	2 072 455	427 000	16 465 000
anciennete_activite_annees	5,9	4,0	5,9	0	35
score_bureau_credit	596,7	597	99,1	300	850

Variable	Moyenne	Médiane	Écart-type	Min	Max
montant_pret_demande_gnf	2 270 737	1 531 000	2 359 024	300 000	28 219 000
duree_pret_mois	10,4	9	5,9	3	24
ratio_pret_revenu	0,6	0,5	0,5	0,0	3,0

Tableau 2 — Statistiques descriptives des principales variables numériques

2.4 Distribution de la variable cible

La variable cible présente un déséquilibre modéré : 78,9 % des clients (1 183) remboursent leur crédit, tandis que 21,1 % (317) font défaut. Ce déséquilibre, sans être extrême, doit être pris en compte lors de la modélisation pour éviter qu'un modèle ne se contente de prédire systématiquement la classe majoritaire.




Figure 1 Distribution de la variable cible defaut_paiement

2.5 Corrélations entre variables numériques

La matrice de corrélation ci-dessous met en évidence les relations linéaires entre les variables numériques. On observe notamment une corrélation positive entre le montant du prêt demandé et le ratio prêt/revenu, ainsi qu'une relation entre l'historique de retard (a_deja_eu_retard, jours_retard_max_anterieur) et le score du bureau de crédit. Aucune paire de variables ne présente de colinéarité extrême ($|r| > 0,9$) qui justifierait une suppression avant modélisation.




Figure 2 Matrice de corrélation des variables numériques

3. Préparation des données

La préparation des données a été implémentée sous la forme d'un pipeline scikit-learn reproductible, garantissant que les mêmes transformations sont appliquées de façon identique aux données d'entraînement et de test, et pourront l'être ultérieurement aux nouvelles demandes de crédit lors du déploiement.

3.1 Nettoyage

Les doublons éventuels sont supprimés via `drop_duplicates()`. Aucune valeur manquante n'ayant été détectée, aucune ligne n'a dû être retirée pour ce motif.

3.2 Encodage et normalisation

- Variables numériques (11) : imputation des valeurs manquantes par la médiane, puis normalisation par `StandardScaler` (moyenne 0, écart-type 1), nécessaire pour la régression logistique.
- Variables catégorielles (7) : imputation par le mode, puis encodage One-Hot (`OneHotEncoder`, `handle_unknown='ignore'`) afin de gérer d'éventuelles modalités inédites en production.

3.3 Traitement du déséquilibre des classes

Compte tenu du déséquilibre modéré de la variable cible (78,9 % / 21,1 %), une pondération des classes (`class_weight='balanced'`) a été appliquée directement dans les algorithmes plutôt qu'un ré-échantillonnage de type SMOTE. Ce choix a été privilégié car il ne modifie pas la distribution réelle des données et préserve ainsi l'interprétabilité des coefficients de la régression logistique, un critère jugé prioritaire compte tenu de l'exigence réglementaire.

3.4 Séparation entraînement / test

Les données sont scindées en un jeu d'entraînement (80 %, soit 1 200 clients) et un jeu de test (20 %, soit 300 clients), avec stratification sur la variable cible afin de conserver la même proportion de défauts dans les deux sous-ensembles. Un `random_state=42` est fixé pour garantir la reproductibilité des résultats.

4. Modélisation

Conformément aux exigences du projet, trois algorithmes de classification binaire ont été entraînés et comparés sur les mêmes données prétraitées, via le même pipeline scikit-learn.

4.1 Régression Logistique

Modèle interprétable exigé par le régulateur : chaque décision peut être justifiée par la contribution individuelle de chaque variable à la probabilité de défaut. Configuré avec `max_iter=1000` et `class_weight='balanced'`.

4.2 Arbre de Décision

Modèle produisant des règles de décision lisibles sous forme de seuils successifs (ex. « si `score_bureau_credit < 550` et `jours_retard_max_anterieur > 30` alors risque élevé »). Il capture naturellement des effets de seuils non linéaires que la régression logistique ne modélise pas directement.

4.3 Gradient Boosting

Modèle d'ensemble construisant successivement des arbres de décision qui corrigent les erreurs des arbres précédents. Il est généralement le plus performant en termes de prédiction brute, mais au prix d'une interprétabilité moindre, ce qui en fait un modèle de comparaison plutôt qu'un candidat pour la mise en production réglementée.

4.4 Protocole d'évaluation

Les trois modèles sont entraînés sur le même jeu d'entraînement (1 200 clients) et évalués sur le même jeu de test (300 clients, non vu pendant l'entraînement). Les métriques retenues Accuracy, Précision, Rappel, F1-score et ROC-AUC sont détaillées dans la section suivante.

5. Évaluation des modèles

5.1 Tableau comparatif

Modèle	Accuracy	Précision	Rappel	F1	ROC-AUC
Régression Logistique	74,7 %	43,3 %	66,7 %	0,525	0,822
Gradient Boosting	83,0 %	71,4 %	31,7 %	0,440	0,797
Arbre de Décision	76,0 %	42,4 %	39,7 %	0,410	0,627

Tableau 3 — Comparaison des performances des trois modèles sur le jeu de test




Figure 3 Comparaison des modèles selon le ROC-AUC

5.2 Modèle retenu

La Régression Logistique obtient le meilleur ROC-AUC (0,822) et surtout le meilleur rappel (66,7 %) parmi les trois modèles : elle détecte deux tiers des défauts réels du jeu de test. Le Gradient Boosting affiche une accuracy globale supérieure (83,0 %) mais un rappel très faible (31,7 %), signifiant qu'il manque près de sept défauts sur dix — un comportement inadapté à un contexte de microfinance où manquer un défaut coûte cher. L'Arbre de Décision, moins performant sur toutes les métriques, sert essentiellement de point de comparaison. Le modèle retenu pour la mise en production est donc la Régression Logistique, ce qui est également cohérent avec l'exigence réglementaire d'interprétabilité.

5.3 Matrice de confusion et courbe ROC

Sur les 300 clients du jeu de test (237 non-défauts réels et 63 défauts réels), la Régression Logistique au seuil par défaut de 0,5 obtient la matrice de confusion suivante : 182 vrais négatifs, 55 faux positifs, 21 faux négatifs et 42 vrais positifs.




Figure 4 Matrice de confusion de la Régression Logistique (seuil 0,5)




Figure 5 — Courbe ROC de la Régression Logistique (AUC = 0,822)

5.4 Choix du seuil de décision

Le seuil de classification par défaut (0,5) n'est pas nécessairement optimal d'un point de vue métier. En microfinance, le coût d'un défaut non détecté (faux négatif) est généralement supérieur au coût d'un bon client refusé à tort (faux positif), car la perte est directe et immédiate. Deux seuils ont donc été comparés :

Seuil	Accuracy	Précision	Rappel	F1
0,50 (classique)	74,7 %	43,3 %	66,7 %	0,525
0,30 (prudent)	59,7 %	33,3 %	92,1 %	0,489

Tableau 4 Comparaison des seuils de décision pour la Régression Logistique

Au seuil 0,30, le rappel atteint 92,1 % : seuls 5 défauts sur 63 échappent au modèle, contre 21 au seuil 0,50. Le coût de cette prudence accrue est une précision plus faible (33,3 %) — davantage de bons clients sont orientés vers un examen manuel supplémentaire. Ce seuil abaissé est recommandé comme filtre d'alerte, la décision finale restant validée par l'agent de crédit, qui conserve son pouvoir d'appréciation sur les dossiers signalés comme à risque.

6. Interprétation variables les plus explicatives

L'un des atouts majeurs de la Régression Logistique est la lecture directe de ses coefficients, qui indiquent le sens et l'intensité de la contribution de chaque variable (normalisée ou encodée) à la probabilité de défaut.




Figure 6 — Coefficients de la Régression Logistique (facteurs de risque et facteurs protecteurs)

6.1 Facteurs de risque (coefficients positifs)

- ratio_pret_revenu (+0,54) : un prêt élevé par rapport au revenu déclaré est le facteur de risque le plus important.
- secteur Électronique/Téléphonie (+0,44) : ce secteur d'activité est associé à un risque de défaut supérieur, possiblement lié à une plus forte volatilité des marges.

- `jours_retard_max_anterieur` (+0,38) et `a_deja_eu_retard` (+0,34) : un historique de retard de paiement, même ponctuel, est fortement prédictif d'un futur défaut.
- `montant_pret_demande_gnf` (+0,24) : les montants de prêt élevés, en valeur absolue, augmentent également le risque.

6.2 Facteurs protecteurs (coefficients négatifs)

- `score_bureau_credit` (−0,49) : un score de bureau de crédit élevé reste le meilleur indicateur protecteur, malgré les limites de disponibilité de cette donnée pour les commerçants informels.
- `secteur Tissus & Pagnes` (−0,47) et `secteur Quincaillerie` (−0,17) : ces secteurs, historiquement stables sur le marché de Madina, sont associés à un risque de défaut réduit.
- `anciennete_activite_annees` (−0,40) : plus l'activité commerciale est ancienne, plus le risque de défaut diminue un indicateur de stabilité économique du commerçant.
- `garant_disponible = Oui` (−0,14) : la présence d'un garant réduit modérément le risque, conformément à l'intuition métier.

Ces résultats offrent des leviers actionnables pour l'agent de crédit : un ratio prêt/revenu raisonnable, l'ancienneté de l'activité et la disponibilité d'un garant peuvent être discutés et négociés directement avec le client lors de l'entretien d'octroi.

7. Déploiement

7.1 Application Streamlit (minimum requis)

Une application Streamlit locale constitue le livrable minimal de déploiement. Elle permet à l'agent de crédit de saisir le profil du commerçant (revenu, secteur d'activité, historique de crédit, caractéristiques du prêt demandé) et d'obtenir instantanément un score de risque ainsi qu'une recommandation d'octroi ou de refus. Le seuil de décision (0,30 ou 0,50) est ajustable directement dans l'interface, permettant à l'IMF d'adapter sa politique de risque sans réentraîner le modèle. Le modèle sérialisé (.pkl ou .joblib) est chargé depuis le dossier `models/` via le module `src/predict.py`, garantissant une séparation nette entre le code d'entraînement et le code de prédiction.

7.2 Déploiement en ligne et CI/CD (bonus)

En complément, un déploiement en ligne peut être envisagé via Streamlit Community Cloud, Hugging Face Spaces ou une instance AWS EC2, rendant l'outil accessible à distance aux agents de terrain. Un pipeline GitHub Actions peut automatiser les tests et le redéploiement à chaque mise à jour du code sur la branche principale, assurant que l'application reste synchronisée avec la dernière version validée du modèle.

8. Limites et pistes d'amélioration

8.1 Limites actuelles

- Rappel encore imparfait : selon le seuil retenu, entre 5 et 21 défauts sur 63 échappent au modèle sur le jeu de test ; un contrôle humain reste nécessaire pour les dossiers en zone grise.

-
- Données simulées : le jeu de données, bien qu'adapté au contexte du marché de Madina, reste une simulation ; une validation sur un historique réel de l'IMF est indispensable avant toute mise en production.
 - Fiabilité du score bureau de crédit : sa disponibilité et sa qualité pour des commerçants opérant dans l'économie informelle restent à confirmer sur le terrain.

8.2 Pistes d'amélioration

- Enrichir les variables explicatives, notamment avec des données transactionnelles de mobile money et des indicateurs de saisonnalité de l'activité commerciale.
- Tester des approches complémentaires de traitement du déséquilibre (SMOTE, coûts asymétriques dans la fonction de perte) en comparaison de la pondération de classes actuelle.
- Mettre en place un monitoring post-déploiement, permettant de réévaluer périodiquement le modèle à mesure que de nouveaux remboursements (ou défauts) sont observés en conditions réelles.

9. Conclusion

Ce projet a permis de construire, comparer et évaluer trois modèles de scoring de crédit pour une institution de microfinance opérant sur le marché de Madina. La Régression Logistique, retenue comme modèle de production, atteint un ROC-AUC de 0,822 et un rappel de 66,7 % au seuil par défaut — pouvant être porté à 92,1 % avec un seuil de décision abaissé à 0,30, au prix d'une précision réduite. Ce compromis, ajustable selon la politique de risque de l'IMF, s'inscrit pleinement dans la contrainte d'interprétabilité exigée par le régulateur, tout en offrant des leviers d'action concrets — ratio prêt/revenu, ancienneté de l'activité, disponibilité d'un garant — que l'agent de crédit peut mobiliser lors de l'entretien avec le commerçant.